

Ligne de correction du mémoire

Analyse comparative du rapport avec le protocole de soutenance actuel

Documents relus : « Protocole de soutenance JOEL.pdf » (13 pages, 10 septembre 2026) et « Rapport Joel KOURAOGO.pdf » (70 pages, version compilée le 23 septembre 2026).

Objet du guide

Ce document ne modifie pas le mémoire. Il fournit une démarche de correction priorisée, fondée sur les exigences explicites du protocole et sur le contenu effectivement présent dans le rapport. Les observations portent sur l'alignement scientifique, méthodologique, expérimental et rédactionnel.

Diagnostic global

Le rapport possède une structure complète et cohérente avec le plan annoncé : cadre théorique, méthodologie, implémentation, expérimentation et conclusion. Le prototype, la collecte de données, les captures de l'API et les résultats de Qdrant sont documentés. Les corrections prioritaires concernent surtout la conformité du protocole expérimental : la recherche hybride annoncée n'est pas évaluée, plusieurs indicateurs et mesures de performance prévus dans le protocole ne sont pas rapportés, et les requêtes construites à partir des documents favorisent TF-IDF.

Priorité immédiate : ne concluez pas que la recherche vectorielle « améliore » globalement la pertinence tant que le protocole actuel montre TF-IDF supérieur sur le jeu de requêtes contrôlé. Présentez ce résultat avec transparence, puis complétez l'expérimentation avec des requêtes reformulées et la méthode hybride.

1. Correspondance avec le protocole

Exigence du protocole	État dans le rapport	Action à effectuer
Contexte, problématique, objectif général et objectifs spécifiques	Partiellement couvert dans l'introduction générale.	Ajouter une phrase distincte pour l'hypothèse générale et une liste explicite des objectifs spécifiques.
Indexation, recherche sémantique, embeddings, bases vectorielles, similarité, indexation ANN	Couvert au chapitre 1.	Ajouter des références académiques aux définitions et préciser l'algorithme réellement utilisé par Qdrant.
Corpus, prétraitement et architecture	Couvert aux chapitres 2 et 3.	Remplacer le futur par le passé ou le présent descriptif ; préciser les sources, langues, licences et l'unité réellement comptée.
Comparaison mots-clés / vectorielle / hybride	Mots-clés TF-IDF et Qdrant comparés ; hybride seulement citée comme perspective.	Ajouter une expérimentation hybride ou réviser formellement le protocole.
Pertinence, performance et qualité fonctionnelle	Recall, MRR et temps local présents ; évaluation incomplète.	Ajouter les mesures manquantes ou justifier précisément leur exclusion.
Limites et perspectives	Présentes au point 4.8.	Les relier explicitement aux résultats et à l'hypothèse.

Lecture de ce tableau

Les éléments « partiellement couverts » ne sont pas à supprimer : ils doivent être rendus plus explicites, mesurables et reproductibles. Les deux écarts majeurs sont la méthode hybride et le périmètre réel de l'évaluation.

2. Ordre de correction recommandé

Étape 1 — Stabiliser ce que vous évaluez

Définissez une unité d'analyse unique : document source, passage (chunk) ou unité documentaire. Le rapport indique 900 « unités documentaires », mais le système indexe des passages. Indiquez clairement : nombre de fichiers originaux, nombre de passages indexés, taille des passages (120 mots), chevauchement (20 mots), langues, catégories et date de constitution de la collection.

Étape 2 — Aligner l'expérience sur le protocole

Préparez les trois méthodes annoncées : TF-IDF ou BM25 pour la référence lexicale, Qdrant pour la recherche vectorielle et une recherche hybride combinant les deux scores. Utilisez le même corpus, les mêmes requêtes, le même k et les mêmes jugements de pertinence pour les trois méthodes.

Étape 3 — Corriger les requêtes de test

Ne fabriquez pas les requêtes à partir du texte du document pertinent si vous cherchez à démontrer un avantage sémantique. Constituez, par catégorie, des requêtes naturelles et reformulées, avec synonymes et termes différents. Conservez une trace de leur auteur, de leur source et du document ou des documents pertinents.

Étape 4 — Recalculer les résultats

Exécutez le notebook après toute modification du corpus, des requêtes, du modèle ou des paramètres. Exportez les tableaux et conservez la date, les versions, la graine aléatoire et les fichiers de sortie.

Étape 5 — Réécrire l'interprétation

Distinguez ce qui est mesuré de ce qui est supposé. Si TF-IDF reste meilleur, présentez-le comme un résultat valide ; expliquez le rôle du biais lexical et indiquez dans quels scénarios la méthode vectorielle apporte une valeur ajoutée.

Règle de rédaction : chaque affirmation quantitative doit renvoyer à un tableau, une figure, un notebook exécuté ou un fichier de résultats identifiable.

3. Corrections à apporter par partie du mémoire

Introduction générale

- Ajouter un paragraphe bref et isolé intitulé ou formulé comme Hypothèse générale : la recherche fondée sur des embeddings et une base vectorielle devrait améliorer la pertinence pour les requêtes reformulées par rapport à la recherche lexicale.
- Conserver la problématique actuelle, mais annoncer dès l'introduction les trois configurations qui seront réellement comparées. Si l'hybride ne sera pas réalisée, retirer cette promesse de l'introduction et du protocole.
- Ne promettre que les mesures effectivement calculées ; sinon, annoncer que certaines sont hors périmètre et les placer en limite.

Chapitre 1 — État de l'art

- Ajouter une citation scientifique ou une documentation primaire aux définitions de TF-IDF, BM25, embeddings, Sentence Transformers, Qdrant, HNSW, IVF et similarité cosinus.
- Créer un court tableau comparatif des méthodes : recherche lexicale, vectorielle et hybride ; principe, atout, limite, cas d'usage. Ce tableau prépare directement le chapitre expérimental.
- Indiquer explicitement que Qdrant utilise un index ANN et préciser la configuration réellement employée (distance cosinus, HNSW par défaut ou paramètres définis).

Chapitre 2 — Méthodologie

- Remplacer les formulations au futur (« sera », « pourra », « devra ») par le passé ou le présent : le système a été développé et la collection a été évaluée.
- Ajouter un tableau de constitution du corpus : catégorie, langue, source Hugging Face ou autre, format, nombre de documents originaux, nombre de passages, licence et critères d'exclusion.
- Décrire la construction des jugements de pertinence : qui décide, combien de documents pertinents par requête, et comment les désaccords sont résolus.

Chapitre 3 — Implémentation

- Vérifier la cohérence entre les explications, les captures, le code réel et les annexes. Le chapitre annonce que les extraits de code sont en annexe, mais certains blocs de code restent visibles dans le corps du texte.
- Ajouter la configuration matérielle de l'ordinateur utilisé : processeur, RAM, système, et préciser si le calcul est CPU ou GPU.
- Vérifier que l'API et l'interface exposent les fonctions décrites : ajout, recherche, filtres, consultation et téléchargement du document original.

Chapitre 4 — Résultats

- Ajouter les résultats pour tous les k annoncés : 1, 3, 5 et 10. Présenter au moins une courbe ou un tableau récapitulatif par méthode.
- Ajouter Precision@ k aux tableaux de résultats. Si nDCG est conservé dans le protocole, le calculer ; sinon, expliquer formellement son absence et supprimer la promesse correspondante.
- Ajouter la méthode hybride. Sans elle, le chapitre ne satisfait pas entièrement la comparaison prévue dans le protocole.
- Ajouter un sous-tableau de performance : temps de création de l'index, temps d'ajout d'un document, débit d'indexation, mémoire maximale, et résultats à plusieurs tailles de corpus si possible.
- Ajouter une mini-évaluation fonctionnelle : scénarios de recherche, importation, filtre, ouverture/téléchargement ; résultat attendu, résultat observé et statut.

Conclusion générale

- Reprendre explicitement la problématique et l'hypothèse. Distinguer ce que les résultats confirment, nuancent ou ne permettent pas de conclure.
- Ne dire que la recherche vectorielle est plus pertinente que si les requêtes reformulées et les indicateurs le démontrent. Dans les résultats actuels, TF-IDF est supérieur sur le scénario contrôlé.

4. Plan expérimental à appliquer avant la version finale

Jeu de données et requêtes

- Fixer le corpus et générer un manifeste versionné : identifiant de collection, date, sources, catégories, langues, formats, nombre de fichiers, nombre de passages et paramètres de segmentation.
- Créer au moins deux groupes de requêtes : (A) requêtes lexicales proches du document ; (B) requêtes sémantiques reformulées, contenant synonymes ou paraphrases. Ne mélangez pas les deux sans les identifier.
- Pour chaque requête, établir le ou les documents pertinents avant l'exécution des méthodes.

Méthodes et paramètres

- Lexicale : TF-IDF (ou BM25) ; conserver les paramètres exacts : n-grammes, stop words, normalisation et filtre.
- Vectorielle : modèle paraphrase-multilingual-MiniLM-L12-v2, vecteurs 384 dimensions, similarité cosinus, $k \in \{1, 3, 5, 10\}$, Qdrant local.
- Hybride : préciser une formule reproductible, par exemple score final = $\alpha \times$ score lexical normalisé + $(1 - \alpha) \times$ score vectoriel normalisé ; tester plusieurs α et justifier la valeur retenue.
- Exécuter toutes les méthodes sur les mêmes requêtes et calculer les mesures dans le même script ou notebook.

Mesures minimales

Famille	À rapporter	Interprétation
Pertinence	Precision@1, @3, @5, @10 ; Recall@1, @3, @5, @10 ; MRR ou MRR@10 ; nDCG@10 si jugements gradués.	Qualité des résultats et de leur ordre.
Performance	Temps d'encodage, temps de recherche, temps d'indexation, ajout d'un document, débit et mémoire.	Coût technique réel du système.
Qualité fonctionnelle	Import, recherche, filtre, ouverture, téléchargement, erreurs de saisie.	Conformité de l'interface aux besoins.

Point de vigilance sur MRR

Si le premier document pertinent est recherché seulement parmi les dix premiers résultats, utilisez l'expression MRR@10 et donnez sa formule tronquée. Si le classement complet est considéré, utilisez simplement MRR. La notation doit être identique dans le texte, les tableaux, les figures et le notebook.

5. Corrections de forme et de cohérence repérées

Constat	Où il apparaît	Correction manuelle
Références affichées entre crochets inutiles, par exemple « Figure [4] » ou « Tableau [9] ».	Chapitres 3 et 4.	Dans LaTeX, remplacer « Figure~\ref{...} » et « Tableau~\ref{...} » par « Figure~\ref{...} » et « Tableau~\ref{...} ».
Temps verbal prospectif alors que le prototype et l'évaluation existent.	Surtout chapitre 2.	Employer le passé pour les actions réalisées et le présent pour décrire le fonctionnement stable du système.
Bibliographie numérotée de façon discontinue entre bibliographie et webographie.	Pages de références.	Choisir une règle unique avec l'encadreur : liste unique numérotée, ou deux listes clairement séparées avec un style cohérent. Vérifier chaque citation.
Le chapitre 3 annonce des codes en annexe, mais des blocs de code subsistent dans le corps.	Chapitre 3.	Conserver uniquement les extraits indispensables à la compréhension ; déplacer les autres en annexe et mettre à jour les renvois.
Terminologie potentiellement ambiguë : document, unité documentaire, passage, chunk.	Chapitres 2 à 4.	Définir ces termes une fois, puis les employer sans alternance.
Capture du notebook comme source des tableaux.	Chapitre 4.	Conserver la capture comme preuve visuelle, mais citer aussi le fichier de résultats et la date d'exécution.

Vérification des formules

- Conserver les formules TF-IDF, similarité cosinus, Precision@k, Recall@k et MRR ; elles sont utiles et correctement mises en évidence dans la structure actuelle.
- Ajouter la source de chaque formule ou l'ouvrage de référence qui la définit.
- Utiliser les mêmes symboles dans le texte et sous les formules, puis vérifier que chaque symbole est défini immédiatement après la formule.

6. Check-list finale avant dépôt

- ☐ 1. La problématique, l'hypothèse, l'objectif général et les objectifs spécifiques sont tous visibles dans l'introduction.
- ☐ 2. Les trois méthodes du protocole (lexicale, vectorielle, hybride) ont été évaluées ou l'écart au protocole est formellement justifié.
- ☐ 3. Les requêtes sont indépendantes des textes sources ou le biais de construction est clairement distingué et discuté.
- ☐ 4. Les chiffres du chapitre 4 correspondent exactement aux fichiers exportés par le notebook exécuté.
- ☐ 5. Les résultats sont présentés pour tous les k annoncés et comprennent Precision, Recall, MRR/MRR@k, ainsi que nDCG si maintenu.
- ☐ 6. La configuration matérielle et logicielle, les paramètres et la date d'exécution sont indiqués.
- ☐ 7. Les tables comportent un titre au-dessus ; les figures ont une légende sous l'image ; tous les appels « Figure n » et « Tableau n » sont sans crochets.
- ☐ 8. Chaque référence bibliographique citée est présente dans la bibliographie ; aucune entrée inutile ne subsiste.
- ☐ 9. La conclusion répond à la problématique avec les limites réelles du protocole, sans surinterpréter les résultats.
- ☐ 10. Le PDF est recompilé et contrôlé visuellement : table des matières, renvois, tableaux, figures, formules, bibliographie et annexes.

Décision de soutenance à préparer

Préparez trois messages simples et honnêtes : (1) votre système fonctionne et indexe un corpus multilingue équilibré ; (2) le filtre de catégorie améliore les résultats vectoriels dans votre configuration ; (3) TF-IDF reste meilleur sur les requêtes extraites des documents, ce qui justifie une évaluation par requêtes reformulées et une comparaison hybride. Cette transparence renforcera la crédibilité scientifique du mémoire.

Fin du guide

Après avoir appliqué les corrections prioritaires, recompiles le mémoire, réexécute les notebooks, puis vérifie que les valeurs, les captures et les tableaux portent la même date et la même version de collection.